



电商用户流失预警 与挽留ROI测算

——以Olist为例

2026 Mia

B u s i n e s s A n a l y s i s



PART.01

项目介绍

Project Overview

执行摘要

本项目针对巴西电商Olist的高用户流失问题，构建了‘数据清洗 → 用户分层 → 流失预测 → 策略仿真’的端到端分析框架，实现营销成本优化与客户留存提升。

核心结论：通过发放‘满100减10元’折扣券，面向流失率前30%且历史客单价 ≥ 67 元的高价值沉睡以及高价值复购用户，预期可实现20%的ROI。

客户流失

电商平台Olist复购率低、客户持续流失；缺乏用户分层与流失预判，营销预算浪费，召回ROI差。

模型定位

通过RFM聚类+XGBoost定位“高价值+高流失风险”的用户，定向发满100减10的券挽回。

核心产出

精准识别7061名用户，挽留策略预期ROI 20%。

业务痛点

分析方案

落地成效

指标定义与口径说明

观测窗口

本报告数据周期为2016年—2018年。以数据首日2016年9月4日到2018年5月31日为观测窗口。在此窗口收集用户数据做RFM和特征用于训练流失预测模型。

预测窗口

以2018年6月1日到数据最后一个有效订单截止日2018年9月3日为预测窗口。在此窗口获得用户是否流失的标签用于训练流失预测模型。

流失用户

在观测窗口内有消费行为，在预测窗口内没有再次产生有效订单的用户。

核销率

公式为：实际使用优惠券下单用户数/触达优惠券的总人数。本项目根据行业基准结合实际业务假设roi测算时核销率为6%。

挽回率

目标人群中，原本会流失的客户，只因为有优惠券激励所以产生复购订单的比例。排除本来就会有复购行为的用户。本项目业务假设值50%。

营销ROI

公式为： $(\text{营销带来新增毛利} - \text{优惠券总成本}) / \text{优惠券总成本}$

毛利率


根据巴西电商行业平均毛利率做出15%的合理假设。

被挽回客单价

指被优惠券成功挽回的用户，用券下单时的平均订单金额。设为160元是保守加权估计：40%的人仅凑单到满减门槛100元，60%按其历史加权客单价约200元购买，估算得160元。

项目背景与业务问题


流失率环形图



用户留存状况严峻 缺乏首次购买后有效触达

- 以 2016年9月4日到2018年5月31日为观测窗口，99.44%的用户被判定为流失。
- 拆解用户订单量发现，73156位用户即仅完成一次购买便永久沉寂。结合复购率仅2.96%，说明平台极依赖一次性交易。

用户订单量分布



技术栈与流程图

01

用户特征表

- 对原表格数据进行清洗
- 使用窗口函数和CTE构建用户级特征表
- 准备RFM原始值
- 用户流失判断

02

EDA与RFM特征工程

- 使用python进行探索性分析
- 特征变换:R值(取反)、F值与M值(对数化)

03

用户聚类

确定K值并使用Sklearn构建4类用户画像:

- 高价值沉睡用户
- 高价值复购用户
- 低价值新用户
- 低价值沉睡用户

04

流失预测

- 构建XGBoost模型预测流失概率
- 通过AUC和分类报告评估模型

ROI测算

对“高价值+高流失风险”的用户,
定向发满100减10的券挽回。
测算活动ROI为20%。

05

PART.02

RFM与K-Means用户聚类分群

User Segmentation

数据来源与清洗

原始数据来自Kaggle Olist公开数据集，经MySQL清洗后整合为用户级特征宽表

表名	记录数	核心字段	用途
olist_orders_dataset	99441	order_id, customer_id, order_status, order_purchase_timestamp	交易主表，计算R值、F值
olist_order_items_dataset	112650	order_id, price, freight_value	商品明细，计算M值
olist_customers_dataset	99441	customer_unique_id, customer_id	映射用户
user_final_wide_table	75386	customer_unique_id, R,F,M,avg_order_vaule, is_churned	处理后的用户宽表

RFM特征工程

原始数据

- 来源: orders表
order_purchase_timestamp
订单下单时间。
- 处理: 取该用户最晚一笔订单日期, 用观测窗口截止日期减去最后下单日期, 得到距离最后消费的天数。

- 来源: 订单表 order_id。
- 处理: 统计该用户不同有效订单的去重计数, 即观测窗口内用户下单总次数。

- 来源: payments表
payment_value (已包含商品款+运费)
- 处理: 对用户所有订单支付金额求和, 得到观测窗口内用户累计支付总额。

业务特征变换

数值越大, 代表用户越久没有下单。为了符合“数值越大代表表现越好”的聚类算法逻辑, 我们将其取负。

订单量从1 到10, 对数变换保留下单次数的层级差异, 压缩长尾极端值, 为K-Means聚类提供连续、稳定的输入特征。

用户消费金额中少数高消费用户占据极大值, 直接使用原始金额会导致聚类中心被极值用户带偏, 通过 $\log(1 + \text{total_revenue})$ 变换, 我们压缩了长尾端的尺度, 使聚类算法能公平地考量低消费与中等消费用户的差异。

R值

距最后一次下单天数

F值

周期内用户下单总次数

M值

用户消费总金额

K-Means聚类

01

肘部法

K从2增至4时，误差下降明显；K>4后边际收益趋缓，过拟合风险上升，K=4为拐点。

02


轮廓系数

K=3时系数达到局部峰值，k=4的系数次之


03

结论

综合两种方法以及实际业务考虑，K=4，也就是将所有用户分为4类，是业务与统计平衡下的最佳选择。




肘部曲线



轮廓系数

聚类效果评估

RFM聚类PCA降维散点图



PCA降维散点图

累计方差解释率达72.1%

为验证K- Means聚类结果的统计学有效性，我们使用PCA（主成分分析）将R、F、M三维特征投影至二维平面。如上图所示，四类用户在降维空间中呈现出明显的分离趋势，累计方差解释率达72.1%，证明聚类结构在数学上显著成立。

聚类结果与用户画像

R=360天（超过1年未购），已进入“死客”状态，并且仅消费1次，总消费金额偏低，属于早期下单后长期不再消费。

低价值沉睡用户

用户数量最少，是唯一具备复购行为的群体，消费总额高；相比另外三类，流失风险最低，是平台核心忠实用户。

高价值复购用户

K-Means聚类结果统计表

聚类	用户数量	R均值	F均值	M均值	流失率
0	21949	360.34	1	117.42	99.57%
1	29331	114.91	1	70.89	99.40%
2	21876	140.52	1	322.53	99.51%
3	2230	178.37	2.11	307.15	98.21%

样本体量最大，R=115天相对最近，但F和M双低，是近期完成单次消费的低价值用户，流失风险极高。

低价值新用户

高价值沉睡用户

仅单次下单，但M均值高达322.53，单次消费能力很强，距离上次下单已有一段时间，目前处于沉睡状态，

通过K-Means聚类，我们将用户划分为4个群体并制定相对运营策略：

低价值沉睡用户（29.12%）：放弃挽回，自然触达，仅在品牌大促时做一次全量EDM推送，不做硬性营销。

低价值新用户（38.91%）：处于流失边缘，对其进行低成本促活，尝试提升其F值和M值，而非直接发优惠券。

高价值沉睡用户（29.02%）：挽回优先级最高，设立专属召回机制，推送优惠券。

高价值复购用户（2.96%）：运营重心所在，核心目标是缩短其R值防止流失。

PART.03

XGBoost流失预测模型

Churn Prediction

模型选型与实验设计

模型选择

项目以用户是否流失 ($is_churn=1$) 为预测目标。流失与用户行为特征间存在非线性与交互关系,

故选用梯度提升树 `XGBoost` 作为主力模型; 同时以逻辑回归作为线性基准, 在相同特征、同一样本划分下对比, 验证模型选型。

模型特征

特征包括: R 、 F 、平均客单价、平均配送时长、差评数、日均消费额、RFM 聚类标签

其中总消费额 $M = \text{频次 } F \times \text{客单价}$, 为避免冗余与共线性予以剔除。

RFM 聚类标签观测窗口生成、无泄露; 经消融实验保留, 对 LR 是非线性补充

日均消费额定义为 M/R , 为避免 inf 保证两个模型完全相同的输入, 达到公平对比的目的, 本项目写为: 日均消费额 $= M/(R+1)$ 。

模型样本

- 本项目时序划分样本: 观测窗口构建特征, 预测窗口定义流失标签, 规避时间泄露。
- 按 8:2 分层抽样划分训练集与测试集
- 采用 5 折分层交叉验证评估泛化稳定性

XGBoost模型参数设定

重要参数

- max_depth=3
- learning_rate=0.05
- subsample=0.8
- colsample_bytree=0.8
- scale_pos_weight默认1

关键调参：类别权重消融实验

针对流失样本占99.44%的极端不平衡，检验是否使用类别权重参数scale_pos_weight（加权值=负/正 ≈ 0.01 ）

结果显示：两种设置的留出AUC与5折AUC几乎一致，差异均小于一倍标准差，说明类别权重不改变模型排序能力；

但加权后Macro-F1由0.4986降至0.4374，流失用户召回率由100%降至75.46%，即漏掉约25%本应挽留的高风险用户。


结论：本数据正类（流失）为绝对多数类，加权会使模型过度迎合仅0.56%的留存样本、与“尽量完整识别待挽留用户”的业务目标相悖，故最终不使用类别权重（scale_pos_weight=1）。

参数设置		留出AUC	5折AUC均值	5折AUC标准差	Macro-F1	流失类召回率
不加权	scale_pos_weight=1	0.6253	0.5772	0.0342	0.4986	1.0000
加权	scale_pos_weight=0.01	0.6264	0.5813	0.0377	0.4374	0.7546

模型对比与评估结果

01 结果对比

XGBoost与逻辑回归的留出测试集AUC分别为0.6253、0.6309，5折交叉验证AUC差距小于一倍标准差，ROC曲线几乎重合；Lift方面XGBoost在Top10%、Top20%高风险人群上略优，Macro-F1逻辑回归略高两模型互有高低、整体性能相当，不存在显著优劣。



02 模型选择


在效果等价的前提下，最终选用XGBoost，逻辑回归作为线性基准原因：

- XGBoost建模上限更高：后续可以补充浏览、加购等行为特征
- XGBoost无需标准化、对缺失值与特征共线更鲁棒
- XGBoost可直接支撑运营
- XGBoost是工业界流失预警主流方案

模型	留出AUC	Macro-F1	Lift@Top10%	Lift@Top20%	Lift@Top30%	5折AUC均值	5折AUC标准差
XGBoost	0.6253	0.4986	1.0029	1.0029	1.0025	0.5772	0.0342
逻辑回归	0.6309	0.5102	0.9996	1.0016	1.002	0.6012	0.0391

XGBoost特征重要性

XGBoost特征重要性



聚类标签合计贡献约31.8%，验证了"RFM分群+流失预测"组合建模的有效性。

重要性解读

消费频次F（23.3%）与高价值复购人群标签cluster_3（20.3%）贡献最高，用户历史消费惯性与价值分层是流失的核心驱动；

最近消费间隔R（10.5%）与日均消费额（10.4%）构成第二梯队，消费节奏放缓是流失的直接先兆

配送时长、客单价、差评数提供辅助信号，说明履约体验亦影响留存。



补充说明

XGBoost特征重要性仅反映贡献大小、无正负方向，方向结合业务判断——频次越低、R越大（越久未购）流失风险越高。cluster_0重要性为0，是因其簇内流失率达99.57%、已无内部区分度。

结论

运营应重点盯防高价值客群的频次下降与活跃间隔拉长，并辅以物流、差评的体验干预。

模型业务有效性评估



场景	模型AUC	
	XGBoost	逻辑回归
目标客群(聚类2和3)	0.7499	0.6422
全量	0.6253	0.6309

- 营销仅触达聚类2/3，故客群内AUC才是决策依据。XGBoost由全量0.6253提升至0.7499，并以0.108的优势反超逻辑回归，模型在真实投放人群中具备稳定排序能力，验证了模型选型。
- 累计增益图按流失概率降序圈选，Top30%可覆盖30.14%的潜在流失者、方向优于随机；
- Lift稳定在1.005左右（Top20%达1.0053），略优于随机；
- 由于客群流失率高达99.39%（随机基线即 $\approx 99.4\%$ ），累计增益曲线极其贴近对角线并且Lift趋稳，非模型失效，属高基数下的数学必然。



PART.04

挽留策略ROI

Project Overview

挽留策略设计

业务痛点


留存率过低
缺乏有效触达

策略内容

满100减10的营销活动
有效期为发放30日内

目标客群

“高价值+高流失风险”用户



挽留策略ROI测算

核销率6%

电商行业优惠券基准核销率为15%，考虑到Olist电商平台巨量单次消费用户的特殊性，取6%

挽回率50%

Olist电商平台流失用户巨大，并且时间跨度都比较长，所以用户收到优惠券后再次消费极大概率是原本没有复购计划只因为优惠券刺激而消费。所以设一个比较乐观的50%。

毛利率15%

参考综合电商零售水平


被挽留客单价160元

设为160元是保守加权估计:40%的人仅凑单到满减门槛100元，60%按其历史加权客单价约200元购买，估算得160元。


参数假设

ROI 20%

=营销净利润/优惠券总成本



挽留策略分析



券面额与流失挽回率是ROI的两大主导因素：面额越大、盈亏平衡所需挽回率越高、越易亏损；

基准方案"10元券+50%挽回率"对应ROI=20%，只需41.7%挽回率即可回本、留有安全边际。因此券型上克制选择满100减10（不盲目加大面额），

业务上依靠XGBoost精准圈选高价值高风险用户来守住挽回率，方案在合理参数波动区间内稳健可行。

模型局限与优化方向

数据局限

仅有交易侧特征、一次性购买用户约 98%、预测窗口仅 3 个月带来标签噪声，AUC 弱有效（0.58~0.63）；99.44% 高流失率为数据集特性；

优化方向

- 补浏览 / 加购 / 收藏等行为特征；
- 延长预测窗口做稳健性检验；
- 概率校准（Platt/Isotonic）；
- 上线后用 A/B 实验实测真实核销率与挽回率，回填 ROI 并迭代模型；
- 建设实时流失预警闭环。





汇报完毕谢谢

汇报人：Mia

B u s i n e s s A n a l y s i s

